

Γιώργος Σουλαντίκας - Π19153

Εργασία Βιοπληροφορικής, Ακαδημαϊκό Έτος: 2025-2026

(i): Σύνθεση Συμβολοσειρών (Sequence Generation)

Σχετικό αρχείο: src/generation/generate.py

Για τη δημιουργία των δεδομένων, αναπτύχθηκε μια συνάρτηση σύνθεσης συμβολοσειρών βασισμένη στα τέσσερα patterns που δόθηκαν, σύμφωνα με τις οδηγίες της εκφώνησης. Με αυτόν τον τρόπο δημιουργήθηκαν συνολικά 200 συμβολοσειρές, οι οποίες στη συνέχεια κατανεμήθηκαν σε τρία σύνολα: datasetA (20), datasetB (140) και datasetC (40).

(ii): Πολλαπλή Στοίχιση (Multiple Sequence Alignment - MSA)

Σχετικό αρχείο: src/training/alignment.py

Για τις συμβολοσειρές του datasetA, υλοποιήθηκε ένας αλγόριθμος καθολικής στοίχισης. Με βάση το τελευταίο ψηφίο του AM μου, ορίστηκε $\alpha=1$. Επομένως, το σκοροτοπικής ομοιότητας είναι +1, η τοπική ανομοιότητα τιμωρείται με $-\alpha/2$, και η εισαγωγή κενού με $-\alpha$.

Για κάθε ζεύγος ακολουθιών, ο πίνακας δυναμικού προγραμματισμού υπολόγισε τις μεταβάσεις από τους πιθανούς προγόνους: διαγώνια $(i-1, j-1)$ για match/mismatch, και οριζόντια/κάθετα $(i-1, j)$ ή $(i, j-1)$ για κενά.

Η πολλαπλή στοίχιση χτίστηκε σταδιακά, στοιχίζοντας κάθε νέα ακολουθία με το ήδη διαμορφωμένο προφίλ των προηγούμενων.

(iii): Κατασκευή Profile HMM και Εκπαίδευση Viterbi

Σχετικό αρχείο: src/training/hmm.py

Για την κατασκευή και διαχείριση του Profile Hidden Markov Model (HMM), υιοθετήθηκε αντικειμενοστρεφής αρχιτεκτονική μέσω της δημιουργίας της κλάσης "HMM".

- **Τοπολογία & Αρχικοποίηση:** Μέσω της μεθόδου `from_msa()`, το μοντέλο αρχικοποιείται απευθείας από την πολλαπλή στοίχιση του datasetA. Το μοντέλο ορίζει αυστηρά καταστάσεις Ταύτισης (Match), Εισαγωγής (Insert) και Διαγραφής (Delete). Για την αποφυγή μηδενικών πιθανοτήτων, χρησιμοποιήθηκε η τεχνική των pseudocounts (0.01) κατά την κανονικοποίηση των συχνοτήτων.
- **Εκπαίδευση Viterbi (Best-Path):** Υλοποιήθηκε η μέθοδος `decode()` (αλγόριθμος δυναμικού προγραμματισμού Viterbi) για να εξάγει την πιο πιθανή διαδρομή για καθεμία από τις 140 μη-στοιχισμένες ακολουθίες του datasetB. Λόγω των

"σιωπηλών" καταστάσεων Διαγραφής (Delete) που δεν καταναλώνουν σύμβολα, ο αλγόριθμος εκτελείται σε δύο αυστηρά περάσματα ανά στήλη (Pass 1 για M/I, Pass 2 για D).

- **Επαναξιολόγηση:** Μέσω της συνάρτησης `train()`, ο κώδικας αυτοματοποιεί την εκπαίδευση: "τρέχει" τον αλγόριθμο Viterbi για το σύνολο εκπαίδευσης και τροφοδοτεί άμεσα τις βέλτιστες διαδρομές στις εσωτερικές συναρτήσεις `_retrain_emissions()` και `_retrain_transitions()`, αναπροσαρμόζοντας τους πίνακες του μοντέλου.

(iv): Αξιολόγηση με Any-Path (Forward Algorithm) και Σχολιασμός

Σχετικά αρχεία: `src/training/hmm.py`, `main.py`

Για την τελική αξιολόγηση του εκπαιδευμένου μοντέλου, ενσωματώθηκε η μέθοδος `forward()` στην κλάση HMM (Any-Path μέθοδος). Σε αντίθεση με τον Viterbi που βρίσκει το μέγιστο, ο αλγόριθμος Forward υπολογίζει το άθροισμα των πιθανοτήτων όλων των πιθανών διαδρομών. Η μέθοδος αξιολόγησης εφαρμόστηκε στις 40 ακολουθίες του `datasetC`, καθώς και σε 40 τυχαία παραγόμενες ακολουθίες.

Αποτελέσματα:

- **Σκορ Ακολουθιών datasetC:** Κυμάνθηκαν περίπου από **-18.0** έως **-30.5**.
- **Σκορ Τυχαίων Ακολουθιών:** Κυμάνθηκαν περίπου από **-110.8** έως **-129.6**.

Συμπέρασμα:

Τα παραπάνω σκορ είναι λογαριθμικές πιθανότητες. Επομένως, ένα σκορ κοντά στο -20 είναι τεράστιο συγκριτικά με ένα σκορ γύρω στο -120.

Οι ακολουθίες του `datasetC` πήραν πολύ καλύτερο (λιγότερο αρνητικό) σκορ, επειδή περιέχουν τα ίδια patterns με τα δεδομένα εκπαίδευσης. Το μοντέλο HMM τα αναγνώρισε και τα ευθυγράμμισε εύκολα, με υψηλές πιθανότητες ταύτισης.

Αντίθετα, οι τυχαίες ακολουθίες δεν είχαν αυτά τα μοτίβα. Έτσι, το μοντέλο τις βαθμολόγησε με πολύ χαμηλές πιθανότητες μετάβασης και τους έδωσε μεγάλες ποινές (λόγω ανομοιότητας στα γράμματα).

Αυτή η μεγάλη διαφορά στα σκορ αποδεικνύει ότι το HMM λειτουργεί ως ταξινομητής: μπορεί να ξεχωρίσει με ευκολία ποιες ακολουθίες ανήκουν στη βιολογική «οικογένεια» που του μάθαμε και ποιες είναι απλώς τυχαίος θόρυβος.